JFK Airline Operational Risk Project
详细 LaTeX 项目报告

Based on repository outputs in `jfk-airline-operational-risk`

2026 年 4 月 20 日

目录

1 项目概述 **3**

1.1 项目目标 3

1.2 仓库中的角色分工 3

1.3 本报告的写作目标 4

1.4 项目的风险口径 4

2 数据基础与预处理 **4**

2.1 数据来源与样本范围 4

2.2 字段标准化与可读化 5

2.3 关键衍生变量 5

2.4 描述性结果 6

3 风险识别与风险块映射 **8**

3.1 为什么不能直接照搬 BTS taxonomy 8

3.2 原因结构与分钟占比 8

3.3 风险热力图的构造方法 9

4 频率模型与严重度模型 **10**

4.1 建模对象 10

4.2 候选频率分布：Poisson 与 Negative Binomial 10

4.3 频率模型结果 11
4.4 候选严重度分布：Lognormal 与 Weibull 12
4.5 严重度模型结果 13
4.6 本阶段的解释 14

5 运行状态划分与 Markov 依赖 14
5.1 为何需要状态框架 14
5.2 候选状态规则 14
5.3 规则选择方法 15
5.4 状态划分后的经验特征 16
5.5 Markov 转移矩阵的估计 17
5.6 平稳分布的计算 18
5.7 本阶段的解释 19

6 年度 Aggregate Risk 模拟 19
6.1 模拟框架 19
6.2 状态驱动的模拟步骤 20
6.3 情景乘子设计 20
6.4 年度风险指标 22
6.5 模拟结果 22
6.6 这一阶段的统计含义 23

7 可复现性、局限与结论 24
7.1 可复现流程 24
7.2 项目的主要优点 24
7.3 局限与可以进一步提升的方向 24
7.4 最终结论 25

1 项目概述

1.1 项目目标

本项目研究的不是单次航班是否晚点，而是 **JFK 机场在多年份尺度上的运营扰动风险**。项目围绕一个完整的运营风险分析链条展开：

1. 从 BTS 原始延误原因出发进行风险识别；
2. 对事件频率进行分布拟合，并比较 Poisson 与 Negative Binomial；
3. 对事件严重度进行分布拟合，并比较 Lognormal 与 Weibull；
4. 在机场月份层面定义 normal / disrupted 两类运行状态；
5. 估计两状态 Markov 转移关系；
6. 在不同运营情景下模拟年度 aggregate operational impact。

仓库说明文件已经明确给出这一逻辑链条，这也是本报告组织结构的主线。项目的最终展示文件是中文 HTML 展示页，主建模脚本则负责生成可复现的数据集、图表和风险情景指标。

1.2 仓库中的角色分工

项目中的主要脚本分工如下：

- `scripts/build_operational_risk_assets.py`：生成清洗后的描述性数据集、字段字典和基础图表；
- `scripts/build_multiyear_operational_risk_project.py`：生成建模输入、分布比较结果、状态面板、Markov 转移矩阵、年度情景模拟和主图表；
- `scripts/build_chinese_modeling_process_report.py` 与 `scripts/build_chinese_modeling` 把前面产出的结果组织成中文展示版 HTML。

因此，这个仓库同时兼具 **分析工程管线**与 **课程展示材料**两种属性：一方面它保留了原始数据到结果表的完整过程，另一方面它又将结果包装成适合课程汇报的可视化叙事。

1.3 本报告的写作目标

本报告的目标不是简单复述 README，而是基于仓库中的全部可见内容，对项目过程进行系统重建，特别强调以下几点：

- 数据源、样本范围、清洗逻辑与指标构造；
- 风险分类从 BTS taxonomy 到课程风险语言的映射；
- 频率与严重度分布为何选择这些候选分布，如何通过 AIC 进行筛选；
- 机场月份状态的定义、规则比较与两状态 Markov 链的估计过程；
- 年度 aggregate risk 的 Monte Carlo 模拟结构与情景设计。

1.4 项目的风险口径

项目没有直接把运营扰动转换成货币损失，而是采用 **delay-equivalent minutes** 作为统一损失口径。其核心思想是：延误分钟本身已经来自官方 BTS 数据，取消与备降则通过固定 penalty 合并进同一指标，从而避免在报告阶段引入难以 defend 的 monetary assumption。

设某个月份、某家航司的总运营冲击为 L，则项目采用的损失口径可以写为

$$L = \text{total arrival delay minutes} + 180 \times \text{cancelled arrivals} + 240 \times \text{diverted arrivals}. \quad (1)$$

这个定义会在后续的状态划分、情景模拟和年度风险结果中反复出现，因此它是整套建模链的统一度量基础。

2 数据基础与预处理

2.1 数据来源与样本范围

原始数据来自仓库中的 `data/raw/Airline_Delay_Cause.csv`,字段定义来自 `data/raw/Downloa`
项目脚本首先检查原始文件是否包含 BTS 预期字段，然后筛选到达机场为 `JFK` 的记录，并按年份、月份、航司名称排序。

当前仓库样本覆盖情况如下：

表 1: 样本覆盖范围

指标	数值
原始 JFK 航司月份记录数	570
清洗后记录数	569
移除记录数	1
年份范围	2020–2025
机场月份数量	72
涉及航司数	12
总到达航班量	657,671
总延误分钟	11,125,838
总取消数	18,230
总备降数	1,873

清洗时唯一被删除的记录来自 **无实际运行量**的月份，脚本也检查了是否存在“延误航班数大于总航班数”这类逻辑错误；当前样本没有出现此类逻辑异常。

2.2 字段标准化与可读化

项目先把原始 BTS 字段重命名为更可读的变量名。例如：

- `arr_flights` → `total_arrival_flights`
- `arr_del15` → `delayed_arrivals_15_plus`
- `carrier_delay` → `airline_delay_minutes`
- `late_aircraft_delay` → `late_aircraft_delay_minutes`

此外，脚本还修正了部分航司名称，避免同一航司因命名风格不同而被拆成多个实体。例如“American Airlines Network”被统一为“American Airlines”。

2.3 关键衍生变量

在航司月份层面，项目构造了多类衍生变量，为后续频率建模、严重度建模和状态分析提供基础。

1. 基础比率指标 令某航司在月份 t 的总到达航班量为 F_t，延误航班量为 D_t，取消数为 C_t，备降数为 V_t，则

$$\text{delay_rate}_t = \frac{D_t}{F_t}, \tag{2}$$

$$\text{cancellation_rate}_t = \frac{C_t}{F_t}, \tag{3}$$

$$\text{diversion_rate}_t = \frac{V_t}{F_t}. \tag{4}$$

2. 频率建模用的风险块事件数 项目将 BTS 原始原因重写为三类课程风险块：

$$N_t^{(\text{internal})} = \text{carrier_ct}_t + \text{late_aircraft_ct}_t, \tag{5}$$

$$N_t^{(\text{system})} = \text{nas_ct}_t, \tag{6}$$

$$N_t^{(\text{external})} = \text{weather_ct}_t + \text{security_ct}_t. \tag{7}$$

其中 `carrier_ct`、`weather_ct` 等变量是 BTS 按原因分摊的估算延误班次数，因此可能出现小数。项目在频率模型中使用其四舍五入后的整数版本：

$$\tilde{N}_t^{(b)} = \text{round}(N_t^{(b)}), \qquad b \in \{\text{internal}, \text{system}, \text{external}\}. \tag{8}$$

3. 严重度建模用的平均事件损失 项目没有直接拟合总分钟，而是拟合每类事件的 **平均分钟损失**。设某航司月份中的各风险块总分钟分别为 $M_t^{(\text{internal})}$、$M_t^{(\text{system})}$、$M_t^{(\text{external})}$，则

$$\bar{X}_t^{(\text{total})} = \frac{\text{total arrival delay minutes}_t}{\text{delayed arrivals 15+}_t}, \tag{9}$$

$$\bar{X}_t^{(\text{internal})} = \frac{M_t^{(\text{internal})}}{N_t^{(\text{internal})}}, \tag{10}$$

$$\bar{X}_t^{(\text{system})} = \frac{M_t^{(\text{system})}}{N_t^{(\text{system})}}, \tag{11}$$

$$\bar{X}_t^{(\text{external})} = \frac{M_t^{(\text{external})}}{N_t^{(\text{external})}}, \tag{12}$$

当分母为零时，脚本把对应均值记为 0。

2.4 描述性结果

图 1 展示了多年期月度趋势，图 2 展示了不同延误原因对总分钟的贡献结构。两张图共同说明：风险不是均匀分布在全年中的，且来源也明显集中在内部链条失稳、晚到飞机与 NAS 拥堵上。

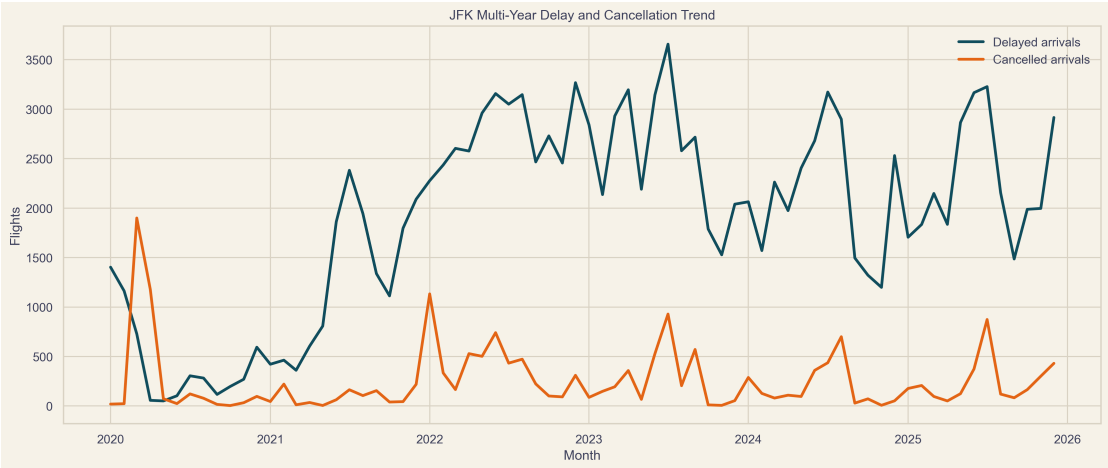

图 1: 多年期月度风险趋势

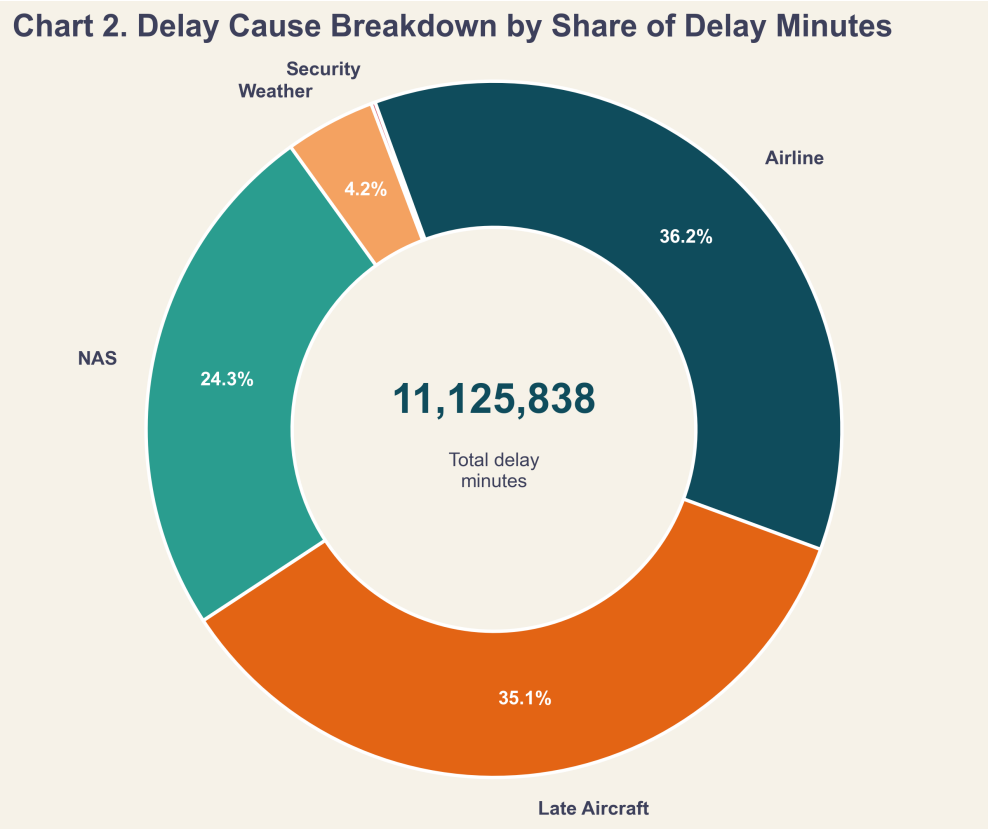

图 2: 延误原因构成

从月度汇总结果看，风险高点明显集中在夏季：

- 7 月延误率最高，达到 0.2785；
- 6 月和 12 月也维持较高延误率；
- 从取消数量看，7 月同样是最高的月份之一。

在航司层面，JetBlue Airways、Delta Air Lines、American Airlines、Endeavor Air 与 Republic Airline 的总延误分钟位于样本前列，其中 JetBlue Airways 的总延误分钟显著高于其他航司。这一结果在风险画像中有助于解释为什么项目后续更强调机场系统层面的状态，而不是把所有结论简单归因于单一航司。

3 风险识别与风险块映射

3.1 为什么不能直接照搬 BTS taxonomy

BTS 的原始分类包含 `Airline`、`Weather`、`NAS`、`Security` 与 `Late Aircraft`。这套 taxonomy 的优点是字段清晰、口径官方统一，但它更像 **数据库口径**，不完全等于课程中的 **运营风险语言**。

项目因此做了以下映射：

$$\text{Internal} = \text{Airline} + \text{Late Aircraft}, \tag{13}$$

$$\text{System} = \text{NAS}, \tag{14}$$

$$\text{External} = \text{Weather} + \text{Security}. \tag{15}$$

这样做的逻辑是：

- `Late Aircraft` 常常不是独立、孤立的外部原因，而是内部排班、飞机轮换、恢复缓冲不足后的传导结果；
- `NAS` 代表系统拥堵与国家空域系统层面的约束，更适合作为 system risk block；
- `Weather` 与 `Security` 都属于外部冲击，虽然量级不同，但管理含义更接近 external shock。

3.2 原因结构与分钟占比

项目处理后的延误原因分钟汇总如下：

表 2: BTS 原始原因的分钟占比

原因	延误分钟	占总延误分钟比例
Airline	4,022,961	36.16%
Late Aircraft	3,910,112	35.14%
NAS	2,705,624	24.32%
Weather	466,088	4.19%
Security	21,053	0.19%

这个结果说明两件事：

1. 内部运行链条相关分钟是绝对主体，因为仅 `Airline + Late Aircraft` 就占到了约 71%；
2. 天气和安保虽然在运营叙事里常被强调，但在当前样本中属于低占比、偏尾部的风险块。

3.3 风险热力图的构造方法

项目没有直接用专家打分法做热力图，而是基于处理后数据构造 **频率代理量**与 **严重度代理量**。

对每个风险块 b，项目先计算：

$$F_b = \text{该风险块在机场月份层面平均每月的分钟规模}, \tag{16}$$

$$S_b = \text{该风险块在机场月份层面平均每月的分钟规模}. \tag{17}$$

这里脚本使用的是机场月份总分钟均值，随后将三个风险块在相互之间做分位排序，并映射到 $\{\text{Low}, \text{Medium}, \text{High}\}$ 三个等级。虽然这不是严格意义上的独立频率与严重度二维分解，但它保留了一个对课程展示很有用的性质：**用统一分钟口径对三大风险块做相对排序**。

热力图结果如下：

表 3: 风险热力图代理量

风险块	频率代理分钟	严重度代理分钟	频率等级	严重度等级
Internal airline-operational disruption	110,181.57	110,181.57	High	High
System/NAS disruption	37,578.11	37,578.11	Medium	Medium
External shock disruption	6,765.85	6,765.85	Low	Low

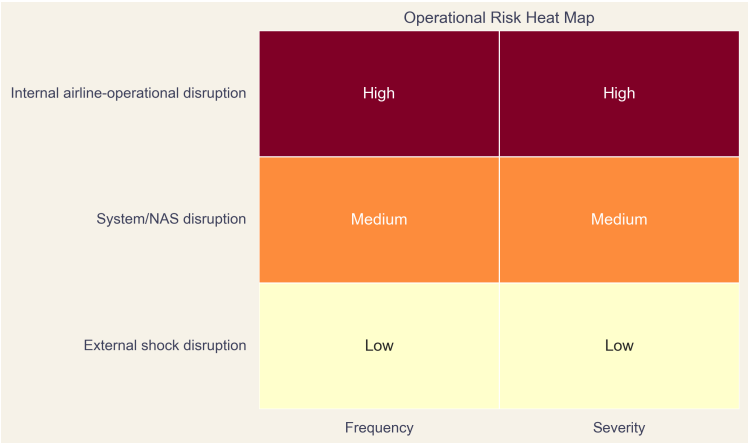

图 3: 风险热力图

因此，项目的风险识别阶段已经给出了后续建模的管理解释基础：**JFK 的主导风险是内部运行链条失稳，其次是系统拥堵，外部冲击更多体现为尾部放大器而非日常主导项。**

4 频率模型与严重度模型

4.1 建模对象

项目把建模对象拆成两部分：

- **频率模型**：拟合事件数量，包括总延误航班数、取消数、备降数，以及 internal/system/external 三类事件数；
- **严重度模型**：拟合单次事件或单位事件的平均损失，包括总延误航班平均分钟、internal/system/external 平均事件分钟。

这样的拆分符合典型 operational risk 建模思路。总体损失不是被直接拟合，而是被分解为

$$L = \sum_{k=1}^{N} X_k, \tag{18}$$

其中 N 是频率随机变量，X_k 是严重度随机变量。项目虽然在最后还加入取消和备降 penalty，但整体思想仍然是标准的 **frequency–severity decomposition**。

4.2 候选频率分布：Poisson 与 Negative Binomial

Poisson 分布 若某类事件数 N 服从 Poisson 分布，则

$$\mathbb{P}(N = n) = \frac{e^{-\lambda}\lambda^n}{n!}, \qquad n = 0, 1, 2, \ldots \tag{19}$$

其均值与方差相等：

$$\mathbb{E}[N] = \lambda, \qquad \mathrm{Var}(N) = \lambda. \tag{20}$$

Poisson 模型适合描述随机、独立、方差与均值同量级的计数过程。

Negative Binomial 分布 若计数存在明显过度离散，即方差显著大于均值，则更适合用 Negative Binomial：

$$\mathbb{P}(N = n) = \binom{n+r-1}{n} p^r (1-p)^n, \qquad n = 0, 1, 2, \ldots \tag{21}$$

其中

$$\mathbb{E}[N] = r\frac{1-p}{p}, \qquad \mathrm{Var}(N) = r\frac{1-p}{p^2}. \tag{22}$$

脚本并没有通过通用数值优化直接做 MLE，而是利用样本均值 $\bar{n}$ 与样本方差 s^2 做矩估式参数恢复：

$$r = \frac{\bar{n}^2}{s^2 - \bar{n}}, \tag{23}$$

$$p = \frac{r}{r + \bar{n}}, \tag{24}$$

当 $s^2 \le \bar{n}$ 时，脚本把分散参数设成一个极大值，退化到近似 Poisson 的情况。

对数似然与 AIC 对任意候选模型 M，项目计算样本对数似然

$$\ell(M) = \sum_{i=1}^{m} \log f_M(x_i), \tag{25}$$

并使用

$$\mathrm{AIC}(M) = 2k - 2\ell(M) \tag{26}$$

进行比较，其中 k 为参数个数。AIC 越小，模型在拟合优度与复杂度之间的综合表现越好。

4.3 频率模型结果

项目结果表明，**所有频率变量最终都选择了 Negative Binomial**。这与数据的过度离散特征一致，例如：

- 总延误航班数均值为 241.21，但方差达到 91,192.93；
- 取消数均值为 32.04，但方差达到 4,403.52；
- 备降数均值为 3.29，但方差达到 29.83。

表 4: 选中的频率模型

变量	选中分布	AIC	normal 状态均值	disrupted 状态均值
total_delay_count	Negative Binomial	7,290.82	207.13	340.87
cancellation_count	Negative Binomial	4,463.27	14.15	84.36
diversion_count	Negative Binomial	2,531.80	2.60	5.30
internal_ops_count	Negative Binomial	6,766.28	132.65	204.68
system_ops_count	Negative Binomial	6,047.51	68.42	124.20
external_ops_count	Negative Binomial	3,502.99	6.06	12.00

状态均值的差异也很重要。disrupted 状态下，总延误事件数、取消数和 system/internal 风险块事件数都显著高于 normal 状态，这为后续 Markov 状态分析提供了统计支持。

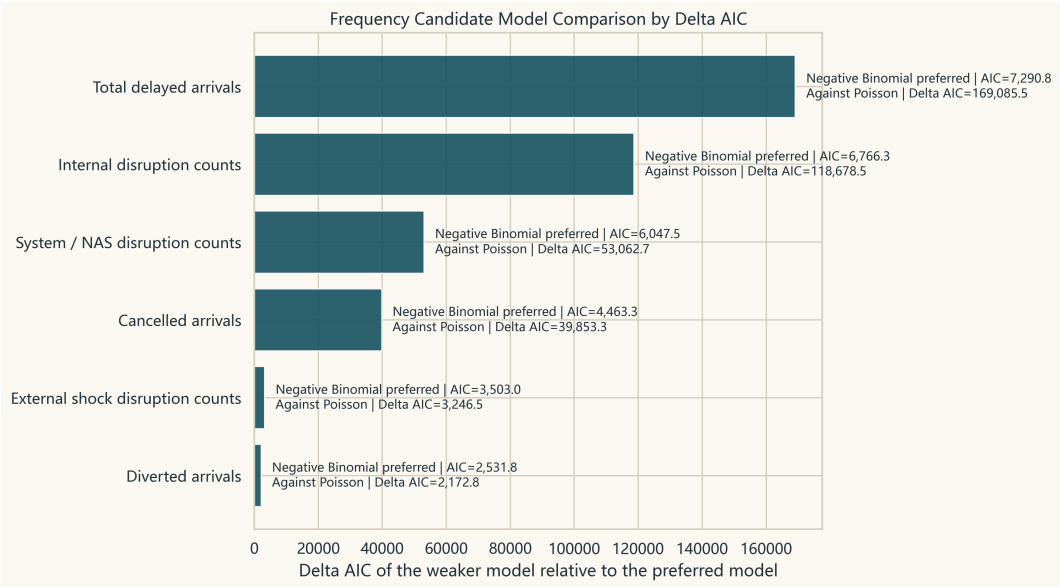

图 4: 频率模型 AIC 比较

4.4 候选严重度分布：Lognormal 与 Weibull

Lognormal 分布 若 $\ln X \sim \mathcal{N}(\mu, \sigma^2)$，则 X 服从 Lognormal 分布，其密度为

$$f(x) = \frac{1}{x\sigma\sqrt{2\pi}} \exp\left(-\frac{(\ln x - \mu)^2}{2\sigma^2}\right), \qquad x > 0. \tag{27}$$

Lognormal 适合描述右偏、长尾、严格为正的损失变量，是 operational risk 中常见的严重度候选分布。

Weibull 分布 Weibull 分布的密度为

$$f(x) = \frac{k}{\lambda}\left(\frac{x}{\lambda}\right)^{k-1} \exp\left[-\left(\frac{x}{\lambda}\right)^{k}\right], \qquad x > 0, \tag{28}$$

其中 k 为形状参数，λ 为尺度参数。Weibull 在拟合寿命型、单峰、正值变量时也很常见。

拟合与选择 脚本使用 `scipy.stats` 的 `fit(..., floc=0)` 对 Lognormal 与 Weibull 进行拟合，并同样使用 AIC 比较。由于严重度变量只在正值样本上有意义，因此项目先过滤掉零值，再对正样本做拟合：

$$\mathcal{D}^{+} = \{x_i : x_i > 0\}. \tag{29}$$

4.5 严重度模型结果

严重度模型的选择不是单一模式，而是变量相关的：

表 5: 选中的严重度模型

变量	选中分布	AIC	normal 状态均值	disrupted 状态均值
total_avg_delay_minutes	Weibull	5,146.84	67.47	76.76
internal_avg_delay_minutes	Lognormal	5,362.19	78.28	83.24
system_avg_delay_minutes	Lognormal	4,413.72	47.83	65.53
external_avg_delay_minutes	Lognormal	4,864.21	103.71	111.83

可以看到：

- 总体延误航班平均分钟更适合用 Weibull；
- 三个风险块的单位事件严重度更适合用 Lognormal；
- external 风险块虽然频率最低，但单位事件平均分钟却是三类中最高的，这说明 external shock 更像低频高损的尾部来源。

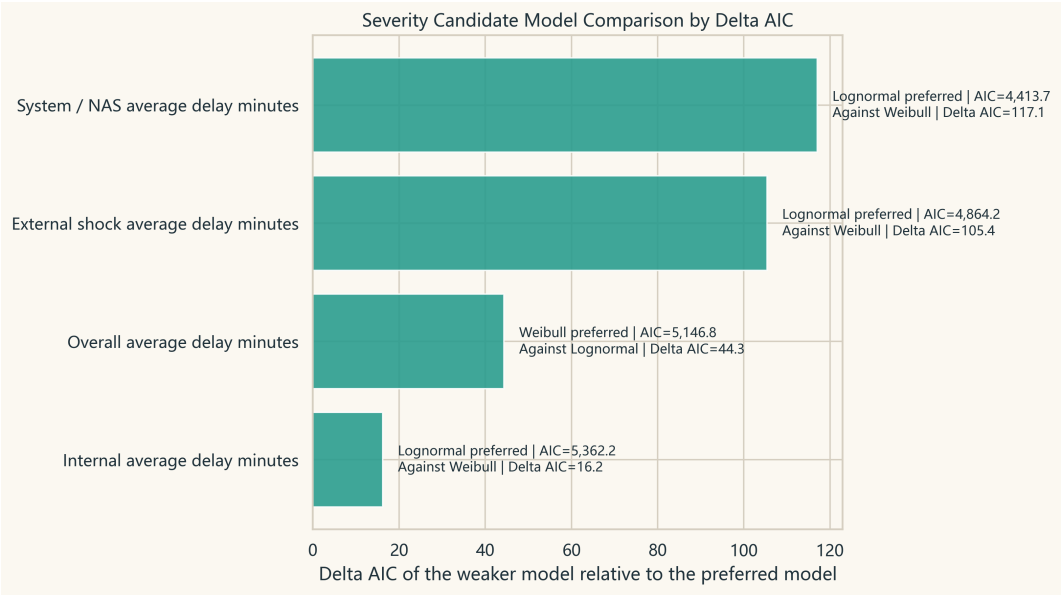

图 5: 严重度模型 AIC 比较

4.6 本阶段的解释

到这一步，项目已经完成了 frequency–severity 分解中最核心的分布选择工作。结果可以概括为：

1. **频率侧存在明显过度离散**，因此 Negative Binomial 全面胜出；
2. **严重度侧没有统一赢家**，说明不同风险块的损失生成机制并不完全相同；
3. **disrupted 状态同时抬高频率与严重度均值**，为后续引入状态依赖与 Markov 机制提供了经验基础。

5 运行状态划分与 Markov 依赖

5.1 为何需要状态框架

如果只使用全样本频率与严重度分布，那么模型默认所有月份来自同一种环境。这与实际运营并不一致：机场存在正常月份，也存在明显高压、恢复困难、取消增加的扰动月份。因此，项目先在机场月份层面定义状态，再讨论状态之间的转移。

5.2 候选状态规则

项目比较了两套状态规则：

1. **impact_q75**：如果月份总冲击高于 `disruption_impact_minutes` 的 75% 分位数，则记为 disrupted；

2. **delay_cancel_impact_composite**：把延误率、取消率和 delay-equivalent minutes 标准化后求和，再取 75% 分位以上为 disrupted。

第二种规则的数学形式为：

$$z_t^{(d)} = \frac{\text{delay_rate}_t - \mu_d}{\sigma_d}, \tag{30}$$

$$z_t^{(c)} = \frac{\text{cancellation_rate}_t - \mu_c}{\sigma_c}, \tag{31}$$

$$z_t^{(L)} = \frac{L_t - \mu_L}{\sigma_L}, \tag{32}$$

$$\text{Composite}_t = z_t^{(d)} + z_t^{(c)} + z_t^{(L)}. \tag{33}$$

然后令

$$\text{state}_t = \begin{cases} \text{disrupted}, & \text{if Composite}_t \geq Q_{0.75}(\text{Composite}), \\ \text{normal}, & \text{otherwise.} \end{cases} \tag{34}$$

5.3 规则选择方法

项目没有主观指定状态规则，而是构造了一个 selection score：

$$\text{score} = |\text{disrupted_share} - 0.25| + \text{std}\,(\text{yearly disrupted share})\,. \tag{35}$$

第一项控制 disrupted 月份占比不要偏离 25%，第二项控制不同年份之间 disrupted 占比的稳定性。分数越低，说明状态定义既保留了“四分之一高风险月份”的直觉，又避免年份之间波动过大。

结果如下：

表 6: 状态规则比较

规则	disrupted 占比	年度占比标准差	disrupted 月数	score	是否
delay_cancel_impact_composite	0.25	0.1521	18	0.1521	Y
impact_q75	0.25	0.1863	18	0.1863	N

因此，项目最终选择 `delay_cancel_impact_composite` 作为状态识别规则。

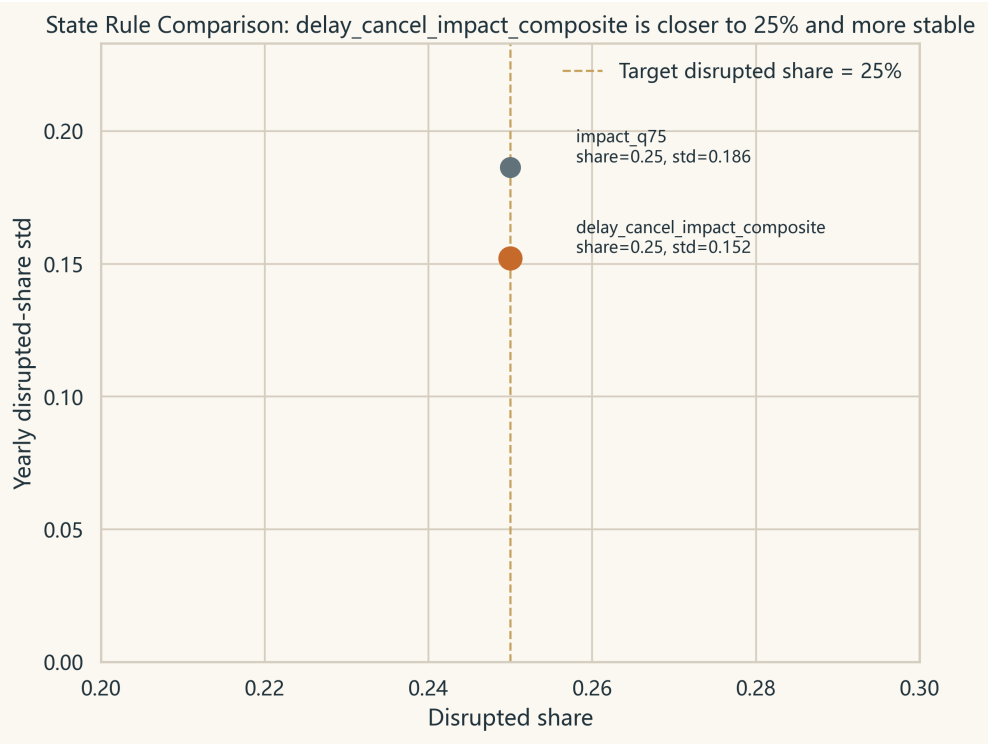

图 6: 状态规则比较图

5.4 状态划分后的经验特征

在最终选中的规则下：

- 72 个机场月份中，54 个为 normal，18 个为 disrupted；
- normal 状态下，平均月度冲击为 149,550.65 分钟；
- disrupted 状态下，平均月度冲击为 376,723.50 分钟；
- normal 状态平均取消率为 0.0147，而 disrupted 状态提高到 0.0811。

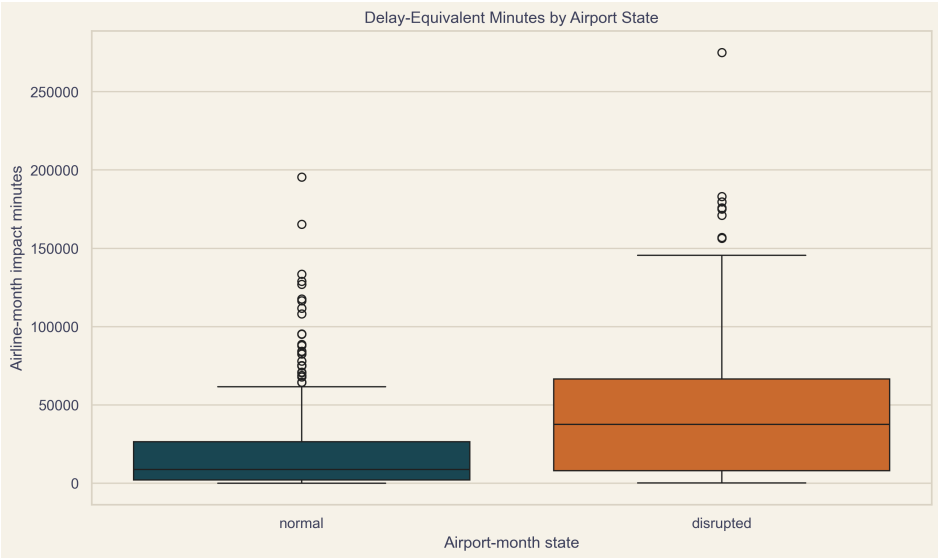

图 7: 不同状态下的航空公司月份冲击分布

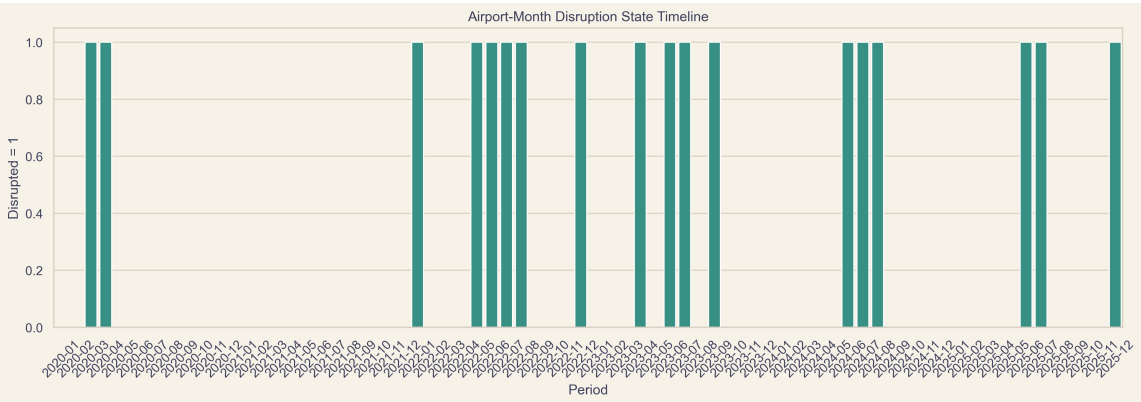

图 8: 机场月份状态时间线

样本中的峰值扰动月份是 2023 年 7 月，其 delay-equivalent minutes 达到 583,999 分钟。随后较高风险月份还包括 2025 年 7 月、2022 年 6 月、2024 年 8 月等。图 8 说明高风险月份并非随机散点，而是呈现出季节性与阶段性聚集。

5.5 Markov 转移矩阵的估计

在状态被定义后，项目按月份时间顺序构造一阶 Markov 链。设状态空间为

$$\mathcal{S} = \{\text{normal}, \text{disrupted}\}. \tag{36}$$

对任意 $i, j \in \mathcal{S}$，转移概率估计为

$$\hat{p}_{ij} = \frac{N_{ij}}{\sum_{k \in \mathcal{S}} N_{ik}}, \tag{37}$$

其中 N_{ij} 表示从状态 i 转移到状态 j 的观察次数。

当前样本得到的转移矩阵为

$$\hat{P} = \begin{bmatrix} 0.814815 & 0.185185 \\ 0.529412 & 0.470588 \end{bmatrix}, \tag{38}$$

其中行对应当前状态，列对应下一期状态，即

$$\hat{P} = \begin{bmatrix} \mathbb{P}(N \to N) & \mathbb{P}(N \to D) \\ \mathbb{P}(D \to N) & \mathbb{P}(D \to D) \end{bmatrix}. \tag{39}$$

对应的转移计数是：

表 7: Markov 转移计数与概率

from	to	计数	概率
normal	normal	44	0.8148
normal	disrupted	10	0.1852
disrupted	normal	9	0.5294
disrupted	disrupted	8	0.4706

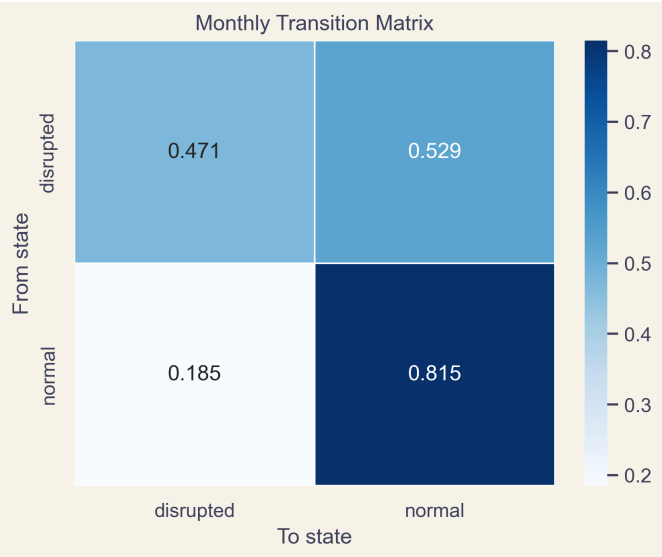

图 9: 两状态 Markov 转移矩阵

5.6 平稳分布的计算

若记平稳分布为 $\boldsymbol{\pi} = (\pi_N, \pi_D)$，则有

$$\boldsymbol{\pi}\hat{P} = \boldsymbol{\pi}, \qquad \pi_N + \pi_D = 1. \tag{40}$$

对二状态链，可直接解得

$$\pi_D = \frac{\hat{p}_{ND}}{\hat{p}_{ND} + \hat{p}_{DN}} = \frac{0.185185}{0.185185 + 0.529412} \approx 0.2591, \tag{41}$$

以及

$$\pi_N = 1 - \pi_D \approx 0.7409. \tag{42}$$

这说明在长期意义上，系统大约有 74.1% 的时间停留在 normal 状态，有 25.9% 的时间停留在 disrupted 状态。这个结果与前面状态规则中 “约四分之一月份为 disrupted” 的设计逻辑是一致的。

5.7 本阶段的解释

Markov 结果可以读成一种非常直接的运营叙事：

- 正常状态具有明显惯性，下一月继续保持 normal 的概率约为 81.5%；
- 一旦进入 disrupted 状态，仍有 47.1% 的概率在下一月继续维持 disrupted；
- 因此，扰动不仅是高损失月份本身，更体现为 **状态持续性与恢复难度**。

6 年度 Aggregate Risk 模拟

6.1 模拟框架

在频率分布、严重度分布与状态转移矩阵都确定之后，项目进入年度风险模拟阶段。其目标不是预测某个具体月，而是给出 **未来一年总 delay-equivalent minutes** 的分布。

设一年有 12 个月。对第 m 个月，先生成状态 $S_m \in \{\text{normal}, \text{disrupted}\}$；再随机抽取一个月度样本中的航司数量 A_m；对每家航司 $a = 1, \ldots, A_m$，按选中的频率模型生成 internal/system/external/cancellation/diversion 事件数，再按选中的严重度模型生成每类事件的平均分钟损失。

于是月度总冲击可以写为

$$L_m = \sum_{a=1}^{A_m} \left(\sum_{k=1}^{N_{m,a}^{(\text{int})}} X_{m,a,k}^{(\text{int})} \; + \; \sum_{k=1}^{N_{m,a}^{(\text{sys})}} X_{m,a,k}^{(\text{sys})} \; + \; \sum_{k=1}^{N_{m,a}^{(\text{ext})}} X_{m,a,k}^{(\text{ext})} \; + \; 180\, C_{m,a} \; + \; 240\, V_{m,a} \right). \tag{43}$$

因此年度总冲击为

$$L_{\text{annual}} = \sum_{m=1}^{12} L_m. \tag{44}$$

项目设置了 500 次 Monte Carlo 模拟，并固定随机种子为 7337，以保证复现性。

6.2 状态驱动的模拟步骤

脚本中的模拟顺序可概括为：

1. 使用 Markov 链或状态占比生成 12 个月的状态序列；
2. 根据状态选择对应的情景乘子；
3. 对每个月抽取月度航司数；
4. 对每家航司，按照选中的频率模型生成 internal/system/external/cancel/divert 五类事件数；
5. 对 internal/system/external 三类事件，按照选中的严重度模型生成平均事件损失并乘以事件数；
6. 对取消与备降直接施加 180 与 240 分钟 penalty；
7. 汇总得到年度总冲击，并在重复模拟后计算均值、VaR 与 TVaR。

6.3 情景乘子设计

项目不是只做单一 baseline，而是引入了 4 类运营情景：

- `base`
- `disruption_stress`
- `weather_shock`
- `holiday_peak`

这些情景通过对频率与严重度施加乘子实现。若某一风险块基准频率均值为 μ，情景乘子为 m，则模拟中使用的调整后均值为

$$\mu^\star = m\mu. \tag{45}$$

对严重度也使用同样思路：

$$X^\star = mX. \tag{46}$$

下表给出脚本中的乘子设置。为便于阅读，仅保留仓库中实际使用的数值。

表 8: 正常状态下的情景乘子

Scenario	internal	system	external	cancel	divert	sev_internal	sev_system	sev_external
base	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00
disruption_stress	1.05	1.10	1.10	1.05	1.05	1.03	1.05	1.05
weather_shock	1.00	1.05	1.25	1.10	1.08	1.00	1.03	1.12
holiday_peak	1.12	1.12	1.08	1.08	1.05	1.05	1.05	1.03

表 9: 扰动状态下的情景乘子

Scenario	internal	system	external	cancel	divert	sev_internal	sev_system	sev_external
base	1.10	1.20	1.25	1.15	1.10	1.05	1.08	1.10
disruption_stress	1.25	1.35	1.45	1.30	1.20	1.10	1.15	1.20
weather_shock	1.05	1.15	1.65	1.40	1.30	1.02	1.08	1.25
holiday_peak	1.22	1.28	1.18	1.22	1.15	1.10	1.12	1.08

6.4 年度风险指标

项目输出以下风险指标：

- **Expected impact**：模拟样本均值；
- **VaR 95%**：95% 分位数；
- **TVaR 95%**：超过 VaR 95% 后的条件均值；
- **VaR 99%**：99% 分位数；
- **TVaR 99%**：超过 VaR 99% 后的条件均值。

若 L 是年度总冲击，则

$$\mathrm{VaR}_\alpha(L) = \inf\{x : \mathbb{P}(L \le x) \ge \alpha\}, \tag{47}$$

而

$$\mathrm{TVaR}_\alpha(L) = \mathbb{E}[L \mid L \ge \mathrm{VaR}_\alpha(L)]. \tag{48}$$

6.5 模拟结果

表 10: 年度 aggregate risk 情景结果

情景	Expected impact	VaR 95%	TVaR 95%	VaR 99%	TVaR 99%
base	2,367,072.82	2,790,834.28	2,911,906.09	3,000,309.69	3,031,286.85
disruption_stress	2,611,594.29	3,121,850.75	3,323,801.55	3,448,514.00	3,536,246.17
weather_shock	2,455,662.60	2,884,871.28	3,016,874.51	3,066,805.62	3,234,528.83
holiday_peak	2,672,396.40	3,182,046.44	3,277,558.29	3,323,075.10	3,417,469.59

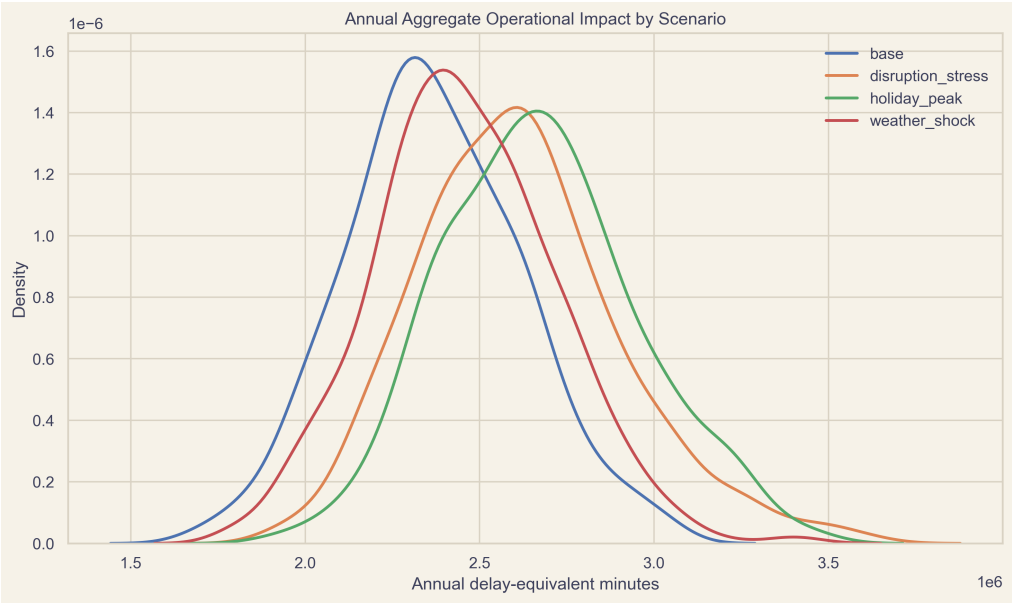

图 10: 不同情景下的年度 aggregate risk 分布

对这些结果可以做如下解读：

- `base` 情景下，年度期望冲击约为 236.7 万分钟；
- `holiday_peak` 的期望冲击最高，说明高峰期流量上升会显著推高年度总损失；
- `disruption_stress` 的尾部指标最重，说明该情景更能放大极端年份的风险；
- `weather_shock` 虽然均值不如前两者高，但在尾部仍然保持较高 TVaR，说明外部冲击主要体现为尾部风险扩张。

6.6 这一阶段的统计含义

从统计上看，项目的 aggregate risk 模块完成了如下整合：

1. 用 Negative Binomial 描述事件数量的过度离散；
2. 用 Lognormal / Weibull 描述事件严重度的右偏分布；
3. 用 Markov 链把 “月份环境” 的持续性显式纳入模拟；
4. 用 scenario multipliers 把管理者关心的运营情景映射为可计算的分布变化。

因此，最终的年度风险不是单一分布假设的产物，而是 **频率、严重度、状态依赖和情景冲击的复合输出**。

7 可复现性、局限与结论

7.1 可复现流程

仓库给出的可复现流程非常清晰。环境配置文件只依赖 Python 3.11 与常见科学计算包，因此复现门槛较低。主流程如下：

1. 创建 `operational_risk` conda 环境；
2. 运行 `build_operational_risk_assets.py` 生成基础清洗结果与描述性图表；
3. 运行 `build_multiyear_operational_risk_project.py` 生成建模输入、模型比较结果、状态面板、Markov 转移矩阵与情景模拟结果；
4. 运行 `build_chinese_modeling_process_showcase.py` 生成最终中文展示版 HTML。

这意味着该项目并非只保留了一份静态报告，而是保留了 **原始数据** → **中间表** → **图表** → **最终展示文件**的完整工程链。

7.2 项目的主要优点

1. **研究问题清楚**：不做单航班预测，而是聚焦运营风险的频率、严重度、状态与年度影响；
2. **损失口径统一**：用 delay-equivalent minutes 避免了主观货币化假设；
3. **方法链完整**：从风险识别到 aggregate simulation 是一条闭环；
4. **复现性强**：关键中间文件和图表都保留在仓库中；
5. **展示友好**：HTML 展示页和图表资产使课程汇报可直接落地。

7.3 局限与可以进一步提升的方向

虽然这个项目结构完整，但从统计建模与风险工程角度看，仍有几个值得说明的局限：

1. **情景乘子是人为设定的**。这对于课程项目是合理的，但若用于正式决策，最好引入更明确的校准依据；
2. **模拟次数只有 500**。对均值足够，但对 99% 尾部指标来说仍可能存在抽样波动；

3. **严重度模型是单变量拟合**。没有进一步控制季节、航司结构或机场状态之外的协变量；

4. **损失单位不是货币**。这让结果更贴近观察数据，但不适合直接用于预算、保险定价或财务资本配置。

7.4 最终结论

综合整个仓库的结果，可以将项目结论概括为以下几点：

1. **JFK 的主导风险来自内部运行链条**，尤其是 airline 与 late aircraft 两部分构成的内部失稳；

2. **NAS 风险是第二层的重要来源**，说明系统拥堵对运营冲击具有显著影响；

3. **external shock 更像低频高损风险**，频率不高，但在尾部情景中能显著放大年度损失；

4. **频率上 Negative Binomial 全面优于 Poisson**，说明计数过程存在明显过度离散；

5. **状态依赖是真实存在的**：一旦进入 disrupted 状态，风险不仅更高，而且具有持续性；

6. **年度 aggregate risk 在不同情景下有明显差异**，因此单一 baseline 无法充分描述运营风险全貌。

从课程项目的角度看，这个仓库已经实现了一个完整、可解释、可复现的运营风险分析样板。它最有价值的地方不在于某一个单独模型，而在于它把 **数据清洗**、**风险识别**、**分布选择**、**状态建模和年度情景模拟**串成了一条逻辑闭环，并通过图表与 HTML 展示页将分析结果转化为可交流、可展示、可复查的成果。